

Hard Disk Failure Data Processing

Corso di Sistemi ed Architetture per Big Data

Luca Falasca Matteo Conti
0334722 0323728

Progetto 1 - Stream processing

2024



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

Indice

1. Introduzione

- Obbiettivi
- Dataset

2. Pipeline

- Data ingestion
- Data processing
- Data Output

3. Conclusioni

- Risultati
- Performance



Introduzione

Obbiettivi

Il progetto verte sull'analisi di un dataset contenente dati riguardanti il monitoraggio di dischi rigidi installati all'interno di un cluster di server gestito da un cloud provider, in particolare si vuole:

- Simulare l'invio in real time dei dati
- Realizzare una pipeline di elaborazione real time dei dati
- Eseguire le query richieste dalla specifica
- Analizzare le performance ottenute



Dataset

Il dataset fornito è una versione ridotta di quello presentato nel Grand Challenge della conferenza ACM DEBS 2024. Delle numerose colonne presenti nel dataset, ne verranno selezionate solamente sette, in particolare:

- *date*: data della misurazione nel formato 'YYYY-MM-DD'
- *serial_number*: identificativo del disco rigido
- *model*: modello del disco rigido
- *s9_power_on_hours*: tempo di accensione del disco rigido in ore
- *s194_temperature_celsius*: temperatura del disco rigido in gradi Celsius
- *vault_id*: identificativo del gruppo di storage server a cui il disco rigido appartiene
- *failure*: flag che indica se il disco rigido ha subito una failure o meno




Pipeline

Pipeline

La pipeline di elaborazione dati è stata containerizzata e deployata tramite docker compose ed è composta da tre componenti:

- Data ingestion
- Data processing
- Data output



Data ingestion

- **Replay Accelerato del Dataset**
 - Fattore di accelerazione: 3600 (1 secondo reale = 1 ora simulata)
- **Granularità Giornaliera**
 - Dati giornalieri spalmati uniformemente
 - Divisione logica della giornata in 150000 parti
 - Ogni parte rappresenta 1/150000 di giorno
- **Invio delle Tuple**
 - Calcolo del tempo di invio della prima tupla
 - Sleep per riempire lo slot residuo dopo l'invio di ogni tupla
 - Sleep finale per riempire il tempo rimanente alla fine della giornata
- **Pubblicazione su Kafka**
 - Dati pubblicati su un topic dedicato
 - Consumo dei dati tramite Flink



Conclusioni



Grazie per l'attenzione